



高电压技术

High Voltage Engineering

ISSN 1003-6520,CN 42-1239/TM

## 《高电压技术》网络首发论文

题目：计及用户充电行为与隐私保护的联邦学习电动汽车短期充电负荷预测  
作者：杨挺，覃小兵，冯相为，许哲铭  
DOI：10.13336/j.1003-6520.hve.20230765  
网络首发日期：2023-08-04  
引用格式：杨挺，覃小兵，冯相为，许哲铭. 计及用户充电行为与隐私保护的联邦学习电动汽车短期充电负荷预测[J/OL]. 高电压技术.  
<https://doi.org/10.13336/j.1003-6520.hve.20230765>



**网络首发：**在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

**出版确认：**纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

DOI: 10.13336/j.1003-6520.hve.20230765

# 计及用户充电行为与隐私保护的联邦学习电动汽车短期充电负荷预测

杨挺, 覃小兵, 冯相为, 许哲铭  
(天津大学电气自动化与信息工程学院, 天津市 300072)

**摘要:** 随着电动汽车迅猛发展, 其充电频率和日充电量急剧增高, 对电网的稳定运行产生了较大的冲击, 因此针对电动汽车的充电负荷预测研究具有重要意义。但由于用户的充电行为数据具有隐私性, 而当前研究构建的机器学习预测模型中欠缺对这一重要因素的考虑, 致使预测精度不高。针对此问题, 本文将**用户的充电起止时间、充电全时段电池荷电状态、电池容量和用户选择的充电功率等**充电行为因素考虑在内, 并考虑上述用户行为数据的隐私性需求, 提出了计及用户充电行为与隐私保护的联邦学习(Federated Learning, FL)电动汽车短期充电负荷预测方法。通过本地训练、中央聚合的模型训练机制在保证用户隐私数据安全的前提下实现电动汽车短期充电负荷协同预测。最后, 利用某市的多家运营商充电负荷数据对所提方法进行验证, 结果表明所提方法在保证用户隐私数据安全的前提下, 有效地提升了电动汽车短期充电负荷预测的精度, 同时具备较好的模型泛化能力。

**关键词:** 电动汽车; 负荷预测; 隐私保护; 用户行为; 联邦学习; 损失函数

## Federated Learning Electric Vehicle Short-Term Charging Load Prediction Accounting for User Charging Behavior and Privacy Protection

YANG Ting, QIN Xiaobing, FENG Xiangwei, XU Zheming  
(School of Electrical and Information Engineering, Tianjin University, Nankai District, Tianjin 300072, China)

**Abstract:** With the rapid development of electric vehicles, their charging frequency and daily charging volume have increased dramatically, which has a great impact on the stable operation of the power grid, so it is important to study the charging load prediction for EVs. However, due to the privacy of users' charging behavior data, the machine learning prediction models constructed in the current study lack the consideration of this important factor, resulting in low prediction accuracy. To address this problem, this paper proposes a Federated Learning (FL) method for short-term EV charging load prediction that considers the user's charging behavior and privacy protection, considering the user's charging start and end times, battery charge status, battery capacity, and user's selected charging power. The method is based on a locally trained, centrally aggregated model. The model training mechanism of local training and central aggregation is used to achieve collaborative short-term EV charging load prediction while ensuring the privacy of user data. Finally, the proposed method is validated using charging load data from several operators in a city, and the results show that the proposed method can effectively improve the accuracy of EV short-term charging load prediction while ensuring the security of user privacy data, and has good model generalization capability.

**Key words:** electric vehicles; load prediction; privacy protection; user behavior; federated learning; loss function

## 0 引言

随着各国碳减排政策的相继提出和可持续发展战略的不断推进<sup>[1-2]</sup>, 电动汽车作为节能减排的重要途径得到了广泛关注, 产业规模迅速扩张,

纯电动汽车数量爆发式增长<sup>[3-6]</sup>。而随之而来的是规模化电动汽车增加的充电负荷给城市配电系统带来了强烈冲击<sup>[7]</sup>。对**电动汽车充电负荷**进行预测以合理地安排调度计划是实现电力系统稳定运行<sup>[8]</sup>、提升电动汽车大规模接入能力的<sup>[9]</sup>的基础, 也是**充电站规划**<sup>[10]</sup>、**电网优化运行**<sup>[11]</sup>和**充放电控制策略制定**<sup>[12]</sup>的重要参考。

针对电动汽车充电负荷预测的研究目前主要集中于两个方面: ①基于历史充电数据的机器学习充电负荷预测研究; ②基于出行链或概率学方

**基金资助项目:** 国家重点研发计划(2022YFB2403900); 国家自然科学基金项目(U2066213); 天津市自然科学基金重点项目(21JCZDJC00640)。Project supported by National Key R&D Program of China (2022YFB2403900); National Natural Science Foundation of China (U2066213); Tianjin Natural Science Foundation Key Project (21JCZDJC00640)。

法的充电负荷预测研究。

文献[13]利用梯度提升、随机森林、极致梯度提升(XGBoost)等机器学习回归算法,对历史充电负荷数据学习,实现用户充电负荷的预测。文献[14]提出基于谱聚类 and 长短期记忆神经网络的电动公交车充电负荷预测方法,利用不同充电负荷数据的距离与形态特性实现谱聚类分簇,进而将不同分簇数据投入不同的长短期记忆(Long Short Term Memory, LSTM)神经网络模型进行差异化的学习与预测,实现总充电负荷的细粒度预测。文献[15]则通过多变量残差校正灰色模型和长短期记忆神经网络的相互配合构建了电动汽车负荷预测的复合模型。但机器学习模型在实际部署中需要大量包含用户隐私的数据,因此具有一定局限性。

在基于出行链或概率学方法进行充电负荷预测方面,则是通过对时空分布、充电偏好等进行理论分析和物理建模,进行充电负荷预测。文献[16]建立了计及出行日类型和交通高峰期的蒙特卡洛电动汽车充电负荷预测模型,实现对充电负荷时空分布的预测。文献[17]则构建了基于时刻充电概率的蒙特卡洛充电负荷预测模型。文献[18]基于交通流模型和 M/M/s 排队理论,通过 Dijkstra 最优路径规划算法进行充电站充电负荷的预测。但上述方法由于需要理论分析,建立对应的物理模型,因此当场景复杂和考虑多维因素时,则难以建立准确的模型或所建立的高维模型无法求解。故此类建模方法预测精度较低。

针对以上两类方法所存在的问题,本文提出将用户的充电行为(包含充电起止时间、充电全时段电池荷电状态、电池容量和用户选择的充电功率等)与**历史充电负荷数据**融合统一考虑,提升规模化电动汽车充电负荷预测精度。但电动汽车(尤其是私家车)的充电行为数据包含大量用户隐私信息以及运营商业隐私信息,在实际工程应用中并非能够公开共享共用。面对该问题,本文研究并提出了计及用户充电行为与隐私保护的联邦学习电动汽车短期充电负荷预测方法。算法在本地将多维用户充电行为数据与历史负荷特征共同投入到本地深度学习网络模型中,通过数据不出本地训练、联邦学习中央聚合、参数回代更新模型的机制,保证用户隐私安全的前提下,实现多方联合建模与协同预测。最后,利用多家运营商充电负荷数据对所提方法进行实验验证,结果表明所提方法实现了在保证用户隐私数据安全的前提下,有效地提升电动汽车短期充电负荷预测的精度,同时具备良好的模型泛化能力。

## 1 系统框架

传统的负荷预测模型构建多是集中式的<sup>[19-21]</sup>,如园区用电负荷预测,通过收集用户的负荷时序数据,进行集中式模型训练,从而获得负荷预测

模型。

但分析可知,电动汽车充电负荷不但与获取的历史数据有关,更与充电起止时间、充电起止电池荷电状态、电池容量和用户选择的充电功率等用户充电行为紧密关联。若能够整合充电行为数据,将其作为负荷特征依据,则可通过细粒度特性提升充电负荷预测精度。

但显然上述充电行为数据包含诸多用户隐私,实际运行中难以被公开共享,进而难以被集中式的模型构建共用<sup>[22]</sup>。因此本文提出分布式横向联邦学习框架,用于电动汽车充电负荷预测模型的训练,通过本地化训练避免了数据的交互共享引起的隐私问题,凭借多方协同的模式解决用户数据隐私问题,进而将用户隐私行为数据作为负荷特征实现对预测模型的补充与增强,以提升充电负荷预测的精准度。整体框架如图1所示。

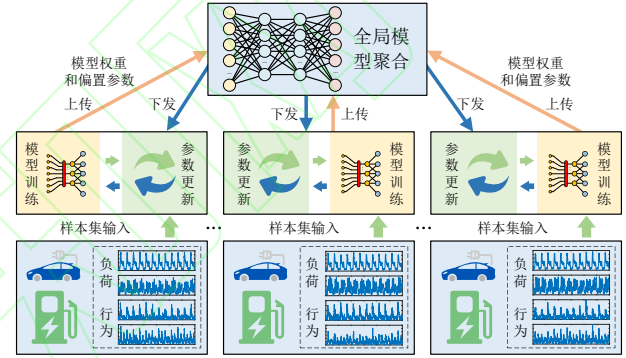


图1 基于横向联邦的电动汽车负荷预测框架  
Fig.1 Electric vehicle load prediction framework based on horizontal federated learning

现阶段充电站运营方式以电动汽车充电运营商(electric vehicle charging operator, EVCO)管辖方式为主<sup>[23]</sup>,某个运营商对于管辖内的充电站、充电桩具有运营权和管理权。拥有获取所管辖区域内电动汽车用户的充电起止时间、充电全时段电池荷电状态、电池容量和用户选择的充电功率以及所有的电动汽车充电功率等本地数据的能力。因此,在本文所提的基于联邦学习的电动汽车充电负荷预测模型框架中,运营商不需要将数据共享出来,而是数据在运营管辖区本地参与模型训练,生成参数参与联邦学习实现调优。通过这种方式,本文所建立框架模型保证了电动汽车用户的行为隐私数据和运营商的负荷数据不被泄露的同时,实现对电动汽车充电负荷的预测。

## 2 基于联邦学习的电动汽车充电负荷预测方法

基于联邦学习的电动汽车充电负荷预测方法整体流程主要包括 EVCO 端本地训练、本地训练模型参数上传、电网公司(Grid Company, GC)侧模型聚合和调优参数下发预测4个步骤。

首先,在最初阶段(迭代轮次  $e=0$ ),GC 对模



型进行初始化, 将模型的初始全局模型权重  $W^e$  和偏置  $B^e$  随机初始化赋值并下发到各个参与方 EVCO。第  $j$  个参与方 EVCO<sub>j</sub> 接收到初始的模型参数后, 更新本地模型权重  $\omega_j^e$  和偏置  $b_j^e$ , 进而利用本地负荷数据集和用户行为数据集作为训练样本进行本地训练并更新本地模型权重  $\omega_j^e$  和偏置  $b_j^e$ , 即 EVCO 端本地训练。然后将本轮本地模型训练更新的权重  $\omega_j^e$  和偏置  $b_j^e$  上传至 GC 进行聚合。GC 在接收到来自各参与方的本地模型相关参数之后, 将所有参数聚合成全局模型, 通过参数调优生成新权重  $W^{e+1}$  和偏置  $B^{e+1}$ , 下发给各参与方 EVCO, 进行下一轮训练和预测。

### 2.1 EVCO 端本地预测模型训练

在 EVCO 本地短期充电负荷滚动预测模型训练时, 本文采用双向长短期记忆(Bi-directional Long Short-Term Memory, BiLSTM)搭建神经网络架构。

为使用户行为离散数据能符合模型的输入, 下面对本地模型的输入数据进行建模, 以构建连续的时序数据集。

记 EVCO 内所有电动汽车用户在  $t$  时刻充满电所需充电量为:

$$\Delta_t = \sum_{\theta=1}^{n_t} (1 - S_t^\theta) \cdot V^\theta \quad (1)$$

其中,  $n_t$  表示  $t$  时刻的电动汽车充电用户数量。  $S_{\theta t}$  表示第  $\theta$  个用户在  $t$  时刻的电池荷电状态,  $V^\theta$  表示第  $\theta$  个用户的电池容量。

记电动汽车用户在  $t$  时刻的平均充电功率为:

$$\bar{\varepsilon}_t = \frac{1}{n_t} \sum_{\theta=1}^{n_t} \varepsilon_t^\theta \quad (2)$$

其中,  $\varepsilon_{\theta t}$  表示第  $\theta$  个用户在  $t$  时刻的充电功率。

记在  $t$  时刻选择结束充电的用户平均电池荷电状态为:

$$\bar{S}_t = \frac{1}{\tilde{n}_t} \sum_{\theta=1}^{\tilde{n}_t} S_t^\theta \quad (3)$$

其中,  $\tilde{n}_t$  表示在  $t$  时刻选择结束充电的用户数量。

由此得出训练数据为负荷时序数据  $p_t$  和行为时序数据  $\Delta_t$ 、 $\bar{\varepsilon}_t$ 、 $\bar{S}_t$  共同构建的样本集。

考虑到电动汽车充电负荷的变换往往与紧邻时刻的充电负荷和用户行为密切相关, 而随着时间的推移, 其相关性则会逐步减弱。因此本文采用单步滑动窗滚动负荷预测方法, 即模型通过不断连续滑动窗口预测相关性最高的下一时刻负荷, 如图 2 所示, 图中除时间外的数字均为归一化处理后的值。

这种基于连续滑动窗口的滚动训练策略, 使模型能够持续学习新的输入负荷和行为数据, 动态地调整网络参数, 从而提高了充电负荷预测的准确性。

负荷+行为 样本集	$t$	$p_t$	$\Delta_t$	$\bar{\varepsilon}_t$	$\bar{S}_t$	$t$	$p_t$	预测值 负荷
	1	0.589	0.556	0.455	0.544	5	0.363	
	2	0.574	0.537	0.426	0.522	6	0.303	
样本3	3	0.529	0.523	0.406	0.470	7	0.297	预测值3
	4	0.429	0.496	0.401	0.449	8	0.216	预测值4
样本4	5	0.363	0.468	0.352	0.378	9	0.183	预测值5
	6	0.303	0.438	0.301	0.340	10	0.084	
样本5	7	0.297	0.367	0.274	0.338	11	0.051	
	8	0.216	0.304	0.220	0.225	12	-0.033	
...	...	...	...	...	...	...	...	...
样本17	17	-0.180	-0.074	-0.112	-0.109	17	-0.333	预测值17
	18	-0.222	-0.137	-0.151	-0.147	18	-0.357	预测值18
样本18	19	-0.267	-0.175	-0.234	-0.189	19	-0.267	
	20	-0.288	-0.216	-0.315	-0.246	20	-0.288	
	21	-0.333	-0.277	-0.325	-0.324	21	-0.180	
	22	-0.357	-0.345	-0.360	-0.340	22	-0.222	

图 2 电动汽车充电负荷滚动预测

Fig.2 Electric vehicle charging load rolling prediction

### 2.2 本地参数提取

电动汽车充电负荷数据和用户行为数据均是时间序列数据集, 使用 Bi-LSTM 算法相较于 LSTM 算法可以同时从前向和后向的时间序列数据中学习特征, 可捕捉更多的负荷和行为序列信息, 从而提高了电动汽车充电负荷模型的预测精度。同时, 电动汽车充电负荷的变化和时间依赖较强, 利用前向和后向的上下文信息, Bi-LSTM 可以更好地建模时间序列数据中的时间依赖关系。

本地参数主要指 Bi-LSTM 中通过样本集参与训练所得的模型权重和偏置参数, 具体如图 3 所示。

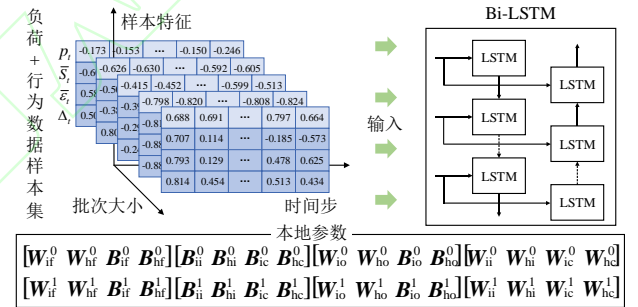


图 3 Bi-LSTM 本地参数

Fig.3 Bi-LSTM local parameters

Bi-LSTM 时序数据处理过程包括遗忘门、输入门和输出门三部分, 如式(4)-式(9)所示。

遗忘门:

$$f_t = \sigma(W_{if}x_t + B_{if} + W_{hf}h_{t-1} + B_{hf}) \quad (4)$$

输入门:

$$i_t = \sigma(W_{ii}x_t + B_{ii} + W_{hi}h_{t-1} + B_{hi}) \quad (5)$$

$$\tilde{C}_t = \tanh(W_{ic}x_t + B_{ic} + W_{hc}h_{t-1} + B_{hc}) \quad (6)$$

输出门:

$$o_t = \sigma(W_{io}x_t + B_{io} + W_{ho}h_{t-1} + B_{ho}) \quad (7)$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{C}_t \quad (8)$$

$$h_t = o_t \odot \tanh(c_t) \quad (9)$$

其中,  $W_{if}$  和  $W_{hf}$  是遗忘门权重参数,  $B_{if}$  和  $B_{hf}$  是遗忘门偏置参数。  $W_{ii}$ 、 $W_{hi}$ 、 $W_{ic}$  和  $W_{hc}$  是输入门权重参数,  $B_{ii}$ 、 $B_{hi}$ 、 $B_{ic}$  和  $B_{hc}$  是输入门偏置参数。

$W_{io}$  和  $W_{ho}$  是输出门权重参数,  $B_{io}$  和  $B_{ho}$  是输出门偏置参数。 $\sigma$  为 sigmoid 激活函数, 其输出范围为  $[0,1]$ , 它能对输入信息的重要程度进行分级, 越接近 1 表示输入的信息越重要。 $\tanh$  激活函数用于将向量中的有效信息提取出来, 能将输出数值始终限制在  $[-1,1]$  之间, 还能防止梯度消失。 $c_t$  为  $t$  时刻的记忆细胞,  $h_t$  为  $t$  时刻的隐藏层状态。

记  $W_i=[W_{if} W_{ii} W_{ic} W_{io}]$ 、 $W_h=[W_{hf} W_{hi} W_{hc} W_{ho}]$ 、 $B_i=[B_{if} B_{ii} B_{ic} B_{io}]$ 、 $B_h=[B_{hf} B_{hi} B_{hc} B_{ho}]$ 。在 Bi-LSTM 架构中, 参数包含正向参数和反向参数, 分别记为权重  $W_i^0$ 、 $W_{0h}$ 、 $W_{1i}$ 、 $W_{1h}$  和偏置  $B_i^0$ 、 $B_{0h}$ 、 $B_{1i}$ 、 $B_{1h}$ 。

整体表示为:

$$W = \begin{bmatrix} W_i^0 & W_h^0 \\ W_i^1 & W_h^1 \end{bmatrix} \quad (10)$$

$$B = \begin{bmatrix} B_i^0 & B_h^0 \\ B_i^1 & B_h^1 \end{bmatrix} \quad (11)$$

分别为模型权重和偏置, 为区分全局模型和本地模型的参数, 全局模型权值和偏置记为  $W$  和  $B$ , 本地模型的权值和偏置记为  $w$  和  $b$ 。注意到在本文方案中, EVCO 向 GC 所传输的参数并非经典联邦学习中的模型梯度, 而是梯度的计算结果: 模型权重和偏置。这种只传递模型权重和偏置有效解决了当参数在传输过程中被非法窃取后, 不法分子难以通过权重和偏置参数推导出原始参与方的本地数据, 从而进一步提升了算法的安全性。

### 2.3 GC 端参数聚合

每个 EVCO 参与方在基于本地充电负荷数据和用户行为数据训练后, 将模型权重  $w_j$  和偏置  $b_j$  上送至 GC 侧进行参数聚合。本文采用联邦随机梯度下降算法(FedSGD)的改进算法(FedAvg)进行参数聚合。在 FedSGD 算法中, 各参与方在每轮通信前只对各自的本地模型参数进行一次梯度下降, 参数更新频率低, 导致各参与方的模型训练不充分, 从而对全局模型的性能带来影响, FedAvg 算法对所有参与方模型参数的更新更加充分, 主要是在每轮本地的模型训练中, 通过提高训练次数增加对本地模型参数的更新次数, 从而提升全局模型的性能。

记联邦学习中第  $j$  个参与方 EVCO <sub>$j$</sub>  的目标函数为:

$$F_j(w_j, b_j; \alpha) = \frac{1}{A} \sum_{d \in \alpha} \varphi_d(w_j, b_j) \quad (12)$$

其中,  $A$  是批样本大小, 即一次训练所选取的样本数,  $\alpha \in P_j$ , 是参与方  $C_j$  的训练样本数据索引集  $P_j$  中由  $A$  个样本组成的一个批次,  $P_j$  是用于标识数据项的标号或编号集;  $\varphi_d(w_j, b_j)$  是当前输入样本在参数  $w_j$  和  $b_j$  下的损失函数。

记联邦学习的总目标函数为:

$$F_G(W, B) = \sum_{j=1}^k \frac{m_j}{m} F_j(w_j, b_j) \quad (13)$$

其中,  $m_j$  是第  $j$  个参与方  $C_j$  的样本集大小,  $m$  是所有参与方的样本集大小总和。

本文采用均方误差(mean square error, MSE)作为本地模型训练的目标损失函数, 即模型预测负荷  $y_{\theta'}$  与真实值  $y_{\theta}$  之间距离平方的平均值, 数值越小表明模型预测值与真实值越为接近, 即模型预测效果越好, 其公式表示如下。

$$\varepsilon_{MSE} = \frac{1}{A} \sum_{\theta=1}^A (y_{\theta'} - y_{\theta})^2 \quad (14)$$

FedAvg 算法的流程如下:

输入: 全局模型网络权重和偏置的初始值  $W_0$  和  $B_0$ , 参与方总个数  $k$ , 全局训练总轮数  $E_G$ , 参与方比例  $\beta$ ,  $m_j$ 。

输出: 最后一次迭代的全局模型权重  $W$  和偏置  $B$ 。

初始化: GC 初始化全局模型权重和偏置为  $W_0$  和  $B_0$ , 初始迭代轮次  $e=0$ 。

迭代  $E_G$  次以下步骤。

步骤一: GC 根据  $\beta \in (0,1]$ , 计算参与第  $e$  轮迭代的参与方个数:

$$n^e = \max(\beta \times k, 1) \quad (15)$$

步骤二: GC 随机选取  $n^e$  个参与方构成参与方集合  $U^e$ 。

步骤三: 接收  $\forall U^e$  传输上来的模型参数。

步骤四: 传输聚合权重  $W^{e+1} = \sum_{j=1}^{n^e} \frac{m_j}{m'} w_j^e$  和偏置

$B^{e+1} = \sum_{j=1}^{n^e} \frac{m_j}{m'} b_j^e$  到所有参与方, 其中  $m'$  表示  $U^e$  的样本总数。

步骤五: 更新迭代轮次  $e$  为  $e+1$ 。

### 2.4 本地参数更新

本地参数更新是对本地充电负荷预测模型权重  $w_j$  和偏置  $b_j$  进行更新, 具体更新流程如下。

输入: 本地模型学习率  $\eta$ , 本地迭代次数  $E_L$ ,  $A$ ,  $U^e$ 。

输出: 本地参与方模型权重  $w_j$  和偏置  $b_j$ 。

对  $\forall j \in U^e$ , 通过以下步骤更新本地模型参数。

步骤一: 使用接收到的全局模型权重  $W^e$  和偏置  $B^e$  进行本地模型参数更新  $w_e \leftarrow W^e$ ,  $b_e \leftarrow B^e$ 。

步骤二: 将  $P_j$  按照  $A$  分为若干个批次, 记由这些批次构成的集合为  $A_j$ 。对集合  $A_j$ , 采用优化算法更新  $E_L$  次本地模型权重  $w_e$  和偏置  $b_e$ , 将更新后的参数上传 GC 端。

在本地负荷预测模型训练中更新权重  $w_j$  和偏置  $b_j$  采用的优化算法为 Adam 算法<sup>[24]</sup>。Adam 算法作为一种自适应学习率的优化算法, 与传统的随机梯度下降算法的不同在于: 随机梯度性下降算法的学习率在整个更新参数的过程中始终保持初

始设定值。而 Adam 算法通过计算梯度的一阶矩估计和二阶矩估计而为不同的参数设计独立的自适应学习率, 使得在训练的不同阶段中, 参数的学习率可以根据其梯度的变化而自适应地调整, 从而提高模型的收敛速度, 计算负荷预测模型权重和偏置的梯度如下式。

$$\mathbf{g}_w = \nabla F_j(\omega_j^e) \quad (16)$$

$$\mathbf{g}_b = \nabla F_j(\mathbf{b}_j^e) \quad (17)$$

同时计算自适应学习率如下式。

$$\mathbf{g}' = \frac{\eta \mathbf{v}'}{\sqrt{s' + \rho}} \quad (18)$$

其中,  $\mathbf{v}'$  和  $\mathbf{s}'$  分别表示梯度的一阶矩和二阶矩的偏置修正,  $\rho$  为常数。然后计算权重和偏置参数如下式。

$$\omega_j^e \leftarrow \omega_j^e - \mathbf{g}'_w \quad (19)$$

$$\mathbf{b}_j^e \leftarrow \mathbf{b}_j^e - \mathbf{g}'_b \quad (20)$$

通过自适应地调整来控制历史梯度的影响, 从而更好地平衡对当前梯度和历史梯度的利用, 可以有效地防止负荷预测模型陷入局部最优解, 并且能够在保持对于充电负荷预测的高精度同时, 大幅减少模型训练的时间和计算资源的开销。

基于联邦学习的电动汽车负荷预测流程如图 4 所示。

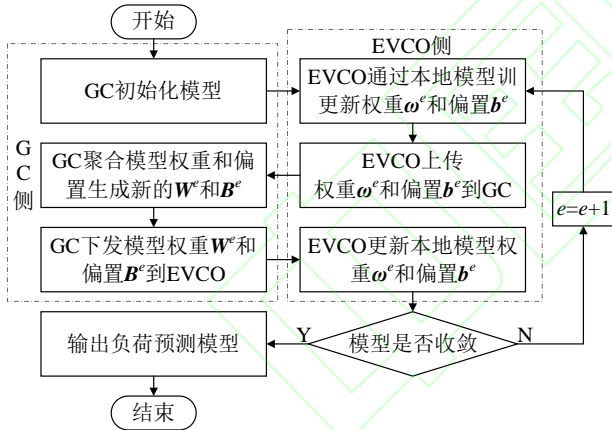


图 4 基于联邦学习的电动汽车充电负荷预测流程

Fig.4 Federated learning based electric vehicle charging load prediction process

### 3 实验测试及算法性能评估

本章针对本文所提方法对预测准确率的提升和方法的可行性做实验验证。采用某市 2022 年 12 月份总计 9 家 EVCO 的充电负荷数据和包含电动汽车用户的充电起止时间、充电起止电池荷电状态、电池容量、用户选择的充电功率等用户行为数据作为实验样本数据集, 数据集总计包含 25920 个采样点的负荷数据和所有用户充电期间的行为数据。每个参与方的数据集按 4:1:1 的比例划分为训练集、验证集和测试集, 并对数据集进行归一化处理。

仿真参数设置如下:  $E_G$  设置为 100,  $E_L$  设置为 5,  $\beta$  设置为 5/9,  $\eta$  设置为 0.01,  $A$  设置为 128,  $k$  设置为 9, 滚动的长度设置为 20。

为了客观评判算法性能, 本文采用平均绝对百分比误差(mean absolute percentage error, MAPE)和均方根误差(root mean square error, RMSE)来量化模型预测的偏差。MAPE 和 RMSE 指标的计算公式如下。

$$E_{\text{MAPE}} = \frac{100\%}{n} \sum_{\theta=1}^n \left| \frac{y'_\theta - y_\theta}{y_\theta} \right| \quad (21)$$

$$E_{\text{RMSE}} = \sqrt{\frac{1}{n} \sum_{\theta=1}^n (y'_\theta - y_\theta)^2} \quad (22)$$

其中,  $n$  为测试样本集大小。

#### 3.1 考虑用户行为与不考虑用户行为的对比实验

首先测试使用用户行为数据集对电动汽车短期充电负荷预测的准确度提升作用。采用相同的预测方法, 图 5 给出使用用户行为数据集和未使用用户行为数据集情况下的 RMSE 和 MAPE 指标的对比。附录 A 图 A1 给出参与方  $C_6$  在测试集上每个采样点的预测偏差(Bias), 即预测值与真实值差同真实值的比值, 计算公式如下式。

$$E_{\text{Bias}} = \frac{\hat{y} - y}{y} \times 100\% \quad (23)$$

其中,  $\hat{y}$  为采样点预测值,  $y$  为采样点真实值。

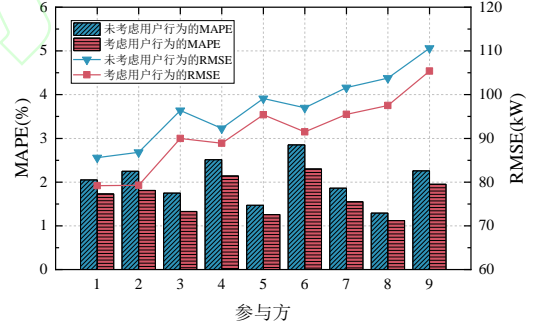


图 5 不考虑用户行为与考虑用户行为的模型 RMSE 与 MAPE 指标对比

Fig.5 Comparison of RMSE and MAPE metrics for the model without considering user behavior and considering user behavior

由图 5 的 RMSE 和 MAPE 的指标对比可以看出, 在模型训练时, 当将用户行为作为充电负荷的影响因子加入训练后, 电动汽车短期充电负荷预测准确度评价指标 RMSE 和 MAPE 均呈现下降趋势, 表明预测模型准确度显著提高。例如参与方  $C_6$  预测的 RMSE 下降 5.57%, MAPE 下降 0.55%。

实验结果表明, 用户的行为数据对充电负荷预测具有重要作用, 证明本文将用电动汽车充电用户行为数据引入短期负荷预测模型中, 能够有效提升模型预测精度。

#### 3.2 本地单一模型与联邦学习模型的对比实验

本节对比单一参与方在本地预测模型训练与



通过协同多方训练的联邦学习模型的预测效果。所有参与方的 RMSE 和 MAPE 预测指标结果对比如图 6 所示,其中参与方  $C_1 \sim C_9$  负荷预测偏差对比如附录 A 图 A2 所示。

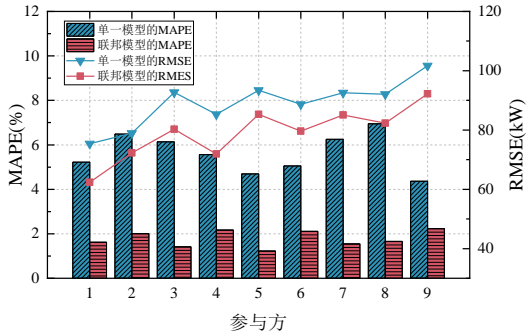


图 6 单一模型和联邦模型 RMSE 与 MAPE 指标对比  
Fig.6 Comparison of single and federated learning model RMSE and MAPE metrics

从图 6 可以看出,通过多方参与构建的联邦学习模型,在对多个 EVCO 的充电负荷预测中表现出比单个 EVCO 本地样本集训练的单一模型具有更高的预测精度。最高性能提升在参与方  $C_8$ ,其 RMSE 降低 11.07%,MAPE 降低 5.29%;即使是性能提升最少的  $C_9$ 其 RMSE 也降低了 9.34%,MAPE 降低了 2.13%。证明本文采用联邦学习策略,在保护了本地数据集隐私的同时,联合了多方参与协同训练充电负荷预测模型,更丰富多样的训练样本集合有力提升了充电负荷预测精度。

### 3.3 模型泛化能力分析实验

为验证通过多方协同构建的联邦模型具有更好的泛化能力,在现有的 9 个参与方之外,新增加一 EVCO 运营商  $C_{10}$ 。作为新进 EVCO 运营商,当前仅记录少量近期历史负荷数据集,同时该 EVCO 当前承载电动汽车用户数量小,充电负荷量低。本文将其投入先前  $C_1 \sim C_9$  训练的联邦学习训练模型中,通过记录 24 小时的电动汽车充电负荷和其充电用户行为数据,用参与方  $C_1 \sim C_9$  九家电动汽车充电运营商联合训练的联邦模型对运营商  $C_{10}$  的未来 24 小时充电负荷进行预测,并对比运营商  $C_{10}$  采用本地的 24 小时数据集训练的本地模型预测未来 24 小时充电负荷的效果。负荷预测对比如图 7 所示,预测偏差如附录 A 图 A3 所示。




图 7  $C_{10}$  负荷预测结果对比  
Fig7  $C_{10}$  load prediction results comparison

由图 7 和附录 A 图 A3 实验数据可知,运营商  $C_{10}$  采用 24 小时的本地数据集进行本地单一模型训练预测得出的 RMSE 指标为 65.3kW,MAPE 指标为 19.2%,表明预测效果极差,这是因为在本地训练样本不足而无法获得有效预测模型。而采用联邦学习模型对运营商  $C_{10}$  的未来 24 小时充电负荷进行预测得出的 RMSE 指标为 29.4kW,MAPE 指标为 6.8%,相比单一模型而言,RMSE 大幅下降了 54.9%,MAPE 下降了 12.4%,表明通过多方协同训练的联邦模型,在学习了多参与方的充电负荷特征情况后,具有较好的模型泛化能力,在应对新的电动汽车充电运营商加入时,表现出快速且准确的预测效果。

## 4 结论

1)针对传统机器学习负荷预测模型特征单一的问题,本文充分考虑了用户行为和充电习惯等因素对充电负荷的影响,将用户的充电起止时间、充电全时段的电池荷电状态、电池容量和用户选择的充电功率等特征作为第二维度与负荷特征共同投入到模型训练过程中,改善了模型的训练效果与预测精度。

2)针对电动汽车负荷预测模型训练过程中出现的用户数据隐私问题,本文提出计及用户充电行为隐私保护的联邦学习电动汽车短期充电负荷预测方法,通过本地训练、中央聚合,保证数据本地化训练的前提下,实现数据的多方安全联合建模。

3)通过对比实验表明,本文所提出的电动汽车充电负荷预测可以在保护用户隐私数据的前提下,提高模型的预测效果的同时,具有较好的模型泛化能力。

## 参考文献 References

- [1] 康丽虹, 贾燕冰, 田 丰, 等. 含 LNG 冷能利用的综合能源系统低碳经济调度[J]. 高电压技术, 2022, 48(2): 575-583.  
KANG Lihong, JIA Yanbing, TIAN Feng, et al. Low-carbon economic dispatch of integrated energy system containing LNG cold energy utilization[J]. High Voltage Engineering, 2022, 48(2): 575-583.
- [2] 贾宏杰, 王梓博, 余晓丹, 等. 城市园区微网系统端对端能量交易技术研究现状与展望[J]. 高电压技术, 2022, 48(7): 2453-2468.  
JIA Hongjie, WANG Zibo, YU Xiaodan, et al. State-of-the-art analysis and perspectives for peer-to-peer energy trading technology in urban community microgrid system[J]. High Voltage Engineering, 2022, 48(7): 2453-2468.
- [3] PARK K, MOON I. Multi-agent deep reinforcement learning approach for EV charging scheduling in a smart grid[J]. Applied Energy, 2022, 328.
- [4] YIN W, QIN X. Cooperative optimization strategy for large-scale electric vehicle charging and discharging[J]. Energy, 2022, 258.
- [5] Global EV Outlook 2022[DB/OL]. (2022-05) [2023-02-7]. <https://www.ica.org/reports/global-ev-outlook-2022>
- [6] 魏雨涵, 孟晓丽, 刘科研.V2G 模式下计及数据不确定性的配电网重构方法[J]. 电力信息与通信技术, 2022, 20(5): 1-8.  
WEI Yuhan, MENG Xiaoli, LIU Keyan. Research.Reconfiguration

- method of distribution network with accounting for data uncertainty in V2G mode[J]. Power Information and Communication Technology, 2022, 20(5): 1-8.
- [7] WANG H, WANG B, FANG C, et al. Charging load forecasting of electric vehicle based on charging frequency[C]// IOP Conference Series: Earth and Environmental Science. Beijing, 2019.
- [8] 郭 瑶, 张新慧, 彭 克, 等. 考虑电动汽车与光伏电源联动的配电网电压调控策略[J]. 电测与仪表, 2019, 56(7): 75-83.
- GUO Yao, ZHANG Xinhui, PENG Ke, et al. Voltage regulation strategy of distribution network considering linkage of electric vehicles and photovoltaic power sources[J]. Electrical Measurement and Instrumentation, 2019, 56(7): 75-83.
- [9] 郝丽丽, 王国栋, 王 辉, 等. 考虑电动汽车入网辅助服务的配电网日前调度策略[J]. 电力系统自动化, 2020, 44(14): 35-48.
- HAO Lili, WANG Guodong, WANG Hui, et al. A day-ahead dispatching strategy for distribution networks considering electric vehicle grid entry auxiliary services[J]. Power System Automation, 2020, 44(14): 35-48.
- [10] ARIAS M B, BAE S. Electric vehicle demand forecasting model based on big data technologies[J]. Applied Energy, 2016, 183: 327-339.
- [11] LIU H, HUANG K, WANG N, et al. Optimal dispatch for participation of electric vehicles in frequency regulation based on area control error and area regulation requirement[J]. Applied Energy, 2019, 240: 46-55.
- [12] 张怡冰, 刘其辉, 洪晨威等. 基于模糊控制的区域电动汽车入网充电调度策略[J]. 电力自动化设备, 2019, 39(7): 147-153.
- ZHANG Yibing, LIU Qihui, HONG Chenwei, et al. Regional electric vehicle charging and discharging scheduling strategy based on fuzzy control into the network[J]. Power Automation Equipment, 2019, 39(7): 147-153.
- [13] LUCAS A, BARRANCO R, REFA N. EV idle time estimation on charging infrastructure, comparing supervised machine learning regressions[J]. Energies, 2019, 12(2): 269.
- [14] 王 哲, 万 宝, 凌天晗, 等. 基于谱聚类和 LSTM 神经网络的电动公交车充电负荷预测方法[J]. 电力建设, 2021, 42(6): 58-66.
- WANG Zhe, WAN Bao, LING Tianhan, et al. Electric bus charging load prediction method based on spectral clustering and LSTM neural network[J]. Power Construction, 2021, 42(6): 58-66.
- [15] FENG J, YANG L, LI Y, et al. Load forecasting of electric vehicle charging station based on grey theory and neural network[C]// The 4th International Conference on Electrical Engineering and Green Energy CEEGE, Munich, 2021.
- [16] 吴 跃. 电动汽车充电负荷预测及其参与电网调度的潜力评估[D]. 南京邮电大学, 2022.
- WU Yue. Electric vehicle charging load forecasting and its potential participation in grid dispatching [D]. Nanjing University of Posts and Telecommunications, 2022.
- [17] 周珊珊, 林永君. 考虑充电行为的电动汽车充电负荷时空分布预测[J]. 工业技术创新, 2022, 9(3): 120-126.
- ZHOU Shanshan, LIN Yongjun. Forecast of spatial and temporal distribution of electric vehicle charging load considering charging behavior[J]. Industrial Technology Innovation, 2022, 9(3): 120-126.
- [18] SU S, ZHAO H, ZHANG H, et al. Forecast of electric vehicle charging demand based on traffic flow model and optimal path planning[C]// 2017 19th International Conference on Intelligent System Application to Power Systems (ISAP). San Antonio, 2017.
- [19] 唐贤伦, 陈洪旭, 熊德意, 等. 基于极端梯度提升和时间卷积网络的短期电力负荷预测[J]. 高电压技术, 2022, 48(8): 3059-3067.
- TANG Xianlun, CHEN Hongxu, XIONG Deyi, et al. Short-term power load forecasting based on extreme gradient boosting and temporal convolutional network[J]. High Voltage Engineering, 2022, 48(8): 3059-3067.
- [20] 蒋建东, 孙书凯, 董 存, 等. 风电中长期电量预测研究现状[J]. 高电压技术, 2022, 48(2): 409-419.
- JIANG Jiandong, SUN Shukai, DONG Cun, et al. Research status of mid-long term wind power generation forecasting[J]. High Voltage Engineering, 2022, 48(2): 409-419.
- [21] 李 卓, 叶 林, 戴斌华, 等. 基于 IDSCNN-AM-LSTM 组合神经网络超短期风电功率预测方法[J]. 高电压技术, 2022, 48(6): 2117-2127.
- LI Zhuo, YE Lin, DAI Binhua, et al. Ultra-short-term wind power prediction method based on IDSCNN-AM-LSTM combination neural network[J]. High Voltage Engineering, 2022, 48(6): 2117-2127.
- [22] YANG Q, LIU Y, CHEN T, et al. Federated machine learning: concept and applications[J]. ACM Transactions on Intelligent Systems and Technology, 2019, 10(2): 1-19.
- [23] 王 鑫, 周步祥, 唐 浩. 考虑用户因素的电动汽车有序充放电控制策略[J]. 电力系统保护与控制, 2018, 46(4): 129-137.
- WANG Xin, ZHOU Buxiang, TANG Hao. Orderly charging and discharging control strategy for electric vehicles considering user factors [J]. Power System Protection and Control, 2018, 46(4): 129-137.
- [24] KINGMA D, BA J. Adam: a method for stochastic optimization[J]. Computer Science, 2014.

## 杨挺 (通信作者)

1979—, 男, 博士, 教授, 博导

主要从事电动汽车负荷预测、物联网安全方面的研究工作

yangting@tju.edu.cn



YANG Ting

Ph. D., Professor



QIN Xiaobing

## 覃小兵

1998—, 男, 硕士生

主要从事电动汽车负荷预测方面的研究工作

qinxiaobing@tju.edu.cn



FENG Xiangwei

## 冯相为

1996—, 男, 博士生

主要从事电动汽车负荷预测方面的研究工作

xwfeng@tju.edu.cn



XU Zheming

## 许哲铭

2000—, 男, 硕士生

主要从事电动汽车负荷预测方面的研究工作

xuzheming@tju.edu.cn

编辑 程子丰



## 附录 A




图 A1 不考虑用户行为与考虑用户行为的模型预测偏差对比

Fig.A1 Comparison of prediction deviations of the model without considering user behavior and considering user behavior

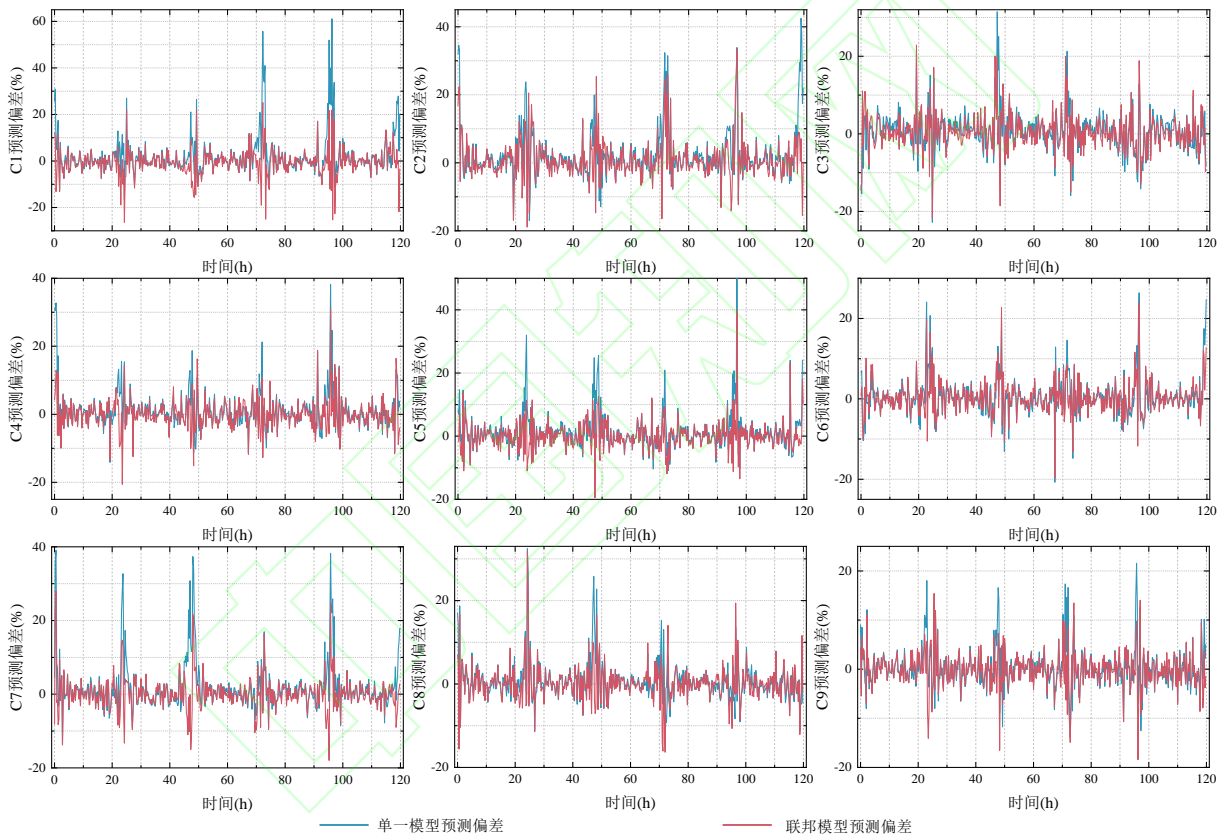
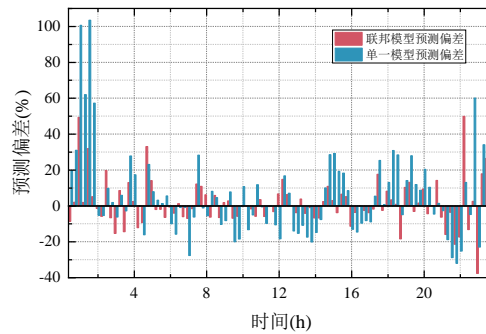


图 A2 单一模型和联邦模型预测偏差对比

Fig.A2 Comparison of prediction deviations of single and federated learning model

图 A3 C<sub>10</sub> 负荷预测偏差对比Fig.A3 C<sub>10</sub> load prediction deviations comparison